Progetto Data Science

Angelo Lapacciana

1 Introduzione

L'obiettivo del seguente progetto è quello di eseguire l'analisi esplorativa e multivariata delle caratteristiche chimiche dei vini, al fine di comprendere le relazioni tra le variabili, ridurre la dimensionalità dei dati e identificare gruppi di vini simili.

Il dataset "*wines*" utilizzato è completo (non ci sono *missing value*) e ha dimensione 178×14, in cui ogni riga rappresenta un singolo campione di vino, mentre le colonne riportano le caratteristiche chimico-fisiche. Le features sono le seguenti:

- **Alcohol**: Contenuto alcolico del vino, espresso in percentuale (%). Influisce sul corpo, sul sapore e sulla conservazione.
- **Malic_Acid**: Acido malico, un acido organico presente nel vino, responsabile dell'acidità e del gusto aspro.
- **Ash**: Ceneri, residuo minerale dopo la combustione del campione; indica la quantità totale di sostanze minerali nel vino.
- **Ash_Alcanity**: Alcalinità delle ceneri, capacità delle ceneri di neutralizzare un acido; misura il contenuto di minerali basici.
- **Magnesium**: Concentrazione di magnesio, un minerale che contribuisce al gusto e alla stabilità chimica del vino.
- **Total_Phenols**: Fenoli totali, importanti per colore, sapore e proprietà antiossidanti.
- **Flavanoids**: Flavonoidi, sottogruppo di fenoli; influenzano colore, astringenza e proprietà antiossidanti.
- **Nonflavanoid_Phenols**: Fenoli non flavonoidi, altri composti fenolici diversi dai flavonoidi; contribuiscono al gusto e alla stabilità.
- **Proanthocyanins**: Proantocianidine, polifenoli che influenzano colore, astringenza e potenziale antiossidante.
- **Color_Intensity**: Intensità del colore, misura la profondità o vivacità del colore del vino, importante per la percezione visiva.
- **Hue**: Tonalità del colore, rapporto tra il colore rosso e giallo; indica il tipo di colore e l'evoluzione del vino.
- **OD280**: Assorbanza a 280 nm, misura spettrofotometrica correlata alla concentrazione di fenoli e altre sostanze aromatiche.
- **Proline**: Prolina, un amminoacido abbondante nel vino; può influenzare sapore e stabilità biologica.
- **Customer_Segment**: etichetta che classifica i vini in gruppi predefiniti.

Dopo aver importato *wines* su Rstudio, ho eliminato la quattordicesima colonna, denominata *Customer_Segment*, poiché voglio lavorare con dati non etichettati.

Durante il progetto, ho esplorato le variabili tramite istogrammi, grafici di densità e boxplot per comprenderne le distribuzioni. Ho poi analizzato le correlazioni tra di esse, ridotto la dimensionalità tramite PCA ed eseguito tecniche di clustering per visualizzare i gruppi di vini tramite **k-means** e **dendrogramma**.

2 EDA - Analisi Esplorativa del Dato

Già dall'osservazione delle caratteristiche delle variabili possiamo intuire una certa ridondanza nei dati. Ad esempio, molte di esse descrivono aspetti legati al colore del vino, altre all'acidità e altre ancora al corpo e alla struttura complessiva. Questo lascia supporre che esista una correlazione interna tra le variabili, e che quindi una riduzione della dimensionalità possa essere utile.

In primis ho visualizzato le features per ognuno dei primi 6 campioni del dataset tramite il comando `head` e che ho presentato in una tabella tramite la funzione `kable` della libreria *knitr*.

Alcohol	**Mal._Ac.**	**Ash**	**Ash_Alc.**	**Magn.**	**Tot._Ph.**	**Flav.**	**Nonfl._Ph.**	**Proa.**	**Color_Int.**	**Hue**	**OD280**	**Proline**
14.23	1.71	2.43	15.6	127	2.80	3.06	0.28	2.29	5.64	1.04	3.92	1065
13.20	1.78	2.14	11.2	100	2.65	2.76	0.26	1.28	4.38	1.05	3.40	1050
13.16	2.36	2.67	18.6	101	2.80	3.24	0.30	2.81	5.68	1.03	3.17	1185
14.37	1.95	2.50	16.8	113	3.85	3.49	0.24	2.18	7.80	0.86	3.45	1480
13.24	2.59	2.87	21.0	118	2.80	2.69	0.39	1.82	4.32	1.04	2.93	735
14.20	1.76	2.45	15.2	112	3.27	3.39	0.34	1.97	6.75	1.05	2.85	1450

Table 1: Valori dei primi sei campioni del dataset *wines*.

Da questa prima analisi si nota che le variabili hanno scale e unità differenti, il che rende necessario standardizzarle prima di applicare tecniche come la PCA o il clustering.

Successivamente, tramite la funzione `summary`, ho ottenuto un riepilogo statistico delle singole features. L'output mostra per ciascuna variabile il valore minimo (Min.), il massimo (Max.), la media aritmetica (Mean), la mediana (Median), cioè il valore centrale della distribuzione, e infine il primo quartile (1st Qu.), che è il valore sotto il quale cade il 25% dei dati, e il terzo quartile (3rd Qu.), che è il valore sotto il quale cade il 75% dei dati. Queste informazioni permettono di avere una prima panoramica della distribuzione dei valori e di individuare eventuali valori anomali.

Variabile	**Min**	**1° Qu.**	**Median**	**Mean**	**3° Qu.**	**Max**
Alcohol	11.03	12.36	13.05	13.00	13.68	14.83
Malic_Acid	0.740	1.603	1.865	2.336	3.083	5.800
Ash	1.360	2.210	2.360	2.367	2.558	3.230
Ash_Alcanity	10.60	17.20	19.50	19.49	21.50	30.00
Magnesium	70.00	88.00	98.00	99.74	107.00	162.00
Total_Phenols	0.980	1.742	2.355	2.295	2.800	3.880
Flavanoids	0.340	1.205	2.135	2.029	2.875	5.080
Nonflavanoid_Phenols	0.1300	0.2700	0.3400	0.3619	0.4375	0.6600
Proanthocyanins	0.410	1.250	1.555	1.591	1.950	3.580
Color_Intensity	1.280	3.220	4.690	5.058	6.200	13.000
Hue	0.4800	0.7825	0.9650	0.9574	1.1200	1.7100
OD280	1.270	1.938	2.780	2.612	3.170	4.000
Proline	278.0	500.5	673.5	746.9	985.0	1680.0

Table 2: Statistiche riassuntive delle variabili chimiche dei vini

Dall'analisi della Tabella 2 emerge che, per la variabile *Magnesium*, la concentrazione dei dati compresa tra il primo e il terzo quartile risulta relativamente ristretta, soprattutto se confrontata con l'ampiezza dell'intervallo che va dal terzo quartile al valore massimo. Ciò suggerisce la possibile presenza di outlier, la cui esistenza sarà verificata in seguito. Si ricorda infatti che un'osservazione è considerata outlier se cade al di fuori dell'intervallo:

$$[Q_1 - 1.5 \cdot IQR,\ Q_3 + 1.5 \cdot IQR]$$

dove $IQR = Q_3 - Q_1$ rappresenta la **distanza interquartilica**. Considerazioni analoghe possono essere estese anche alle variabili *Ash_Alcanity*, *Malic_Acid*, *Proanthocyanins* e *Color_Intensity*.

Ho proceduto con l'analisi visiva dei dati tramite istogrammi per ognuna delle features. Per preparare i dati alla visualizzazione, ho trasformato il dataset da *wide format* a *long format*, tramite il comando `gather`. Questa operazione mi ha permesso di creare un data frame "lungo" in cui tutte le variabili sono raccolte in due colonne: una che indica il nome della variabile (Attributes) e l'altra che contiene i valori corrispondenti (value).

Dopodiché, tramite `ggplot` ho ottenuto il grafico (Figura 1) che mi permette di avere una visione discreta della distribuzione di ciascuna variabile chimica, tramite istogrammi.

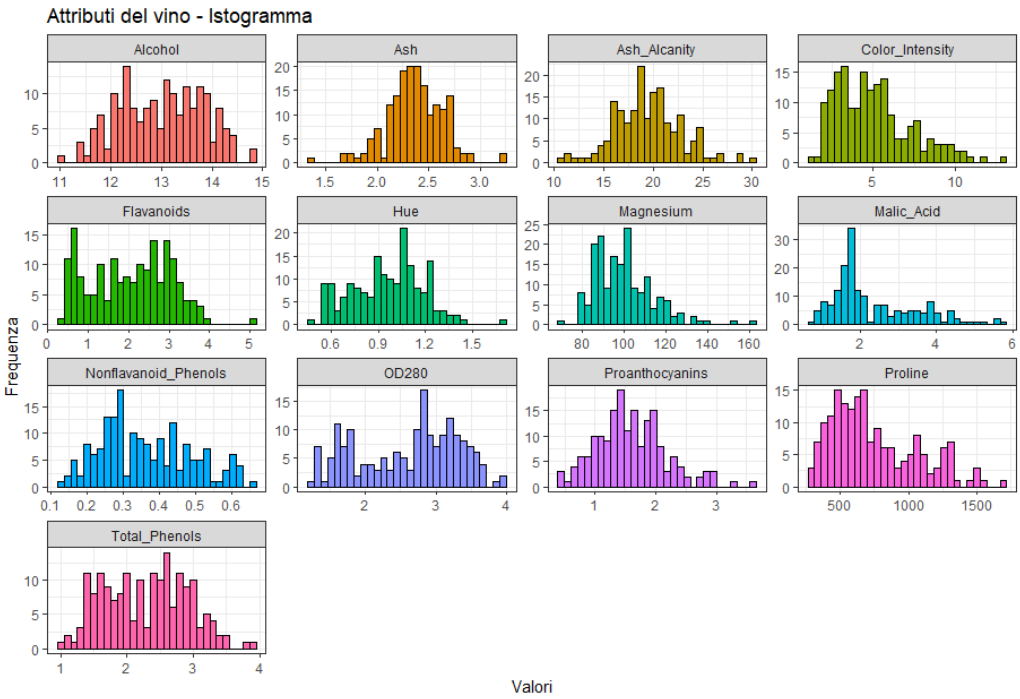

Figure 1: Distribuzione delle caratteristiche chimiche del vino tramite istogrammi.

In maniera analoga, ho rappresentato le variabili tramite grafici di densità (Figura 2), che permettono di coglierne l'andamento in modo più fluido rispetto agli istogrammi, mettendo in risalto eventuali picchi, code e irregolarità.

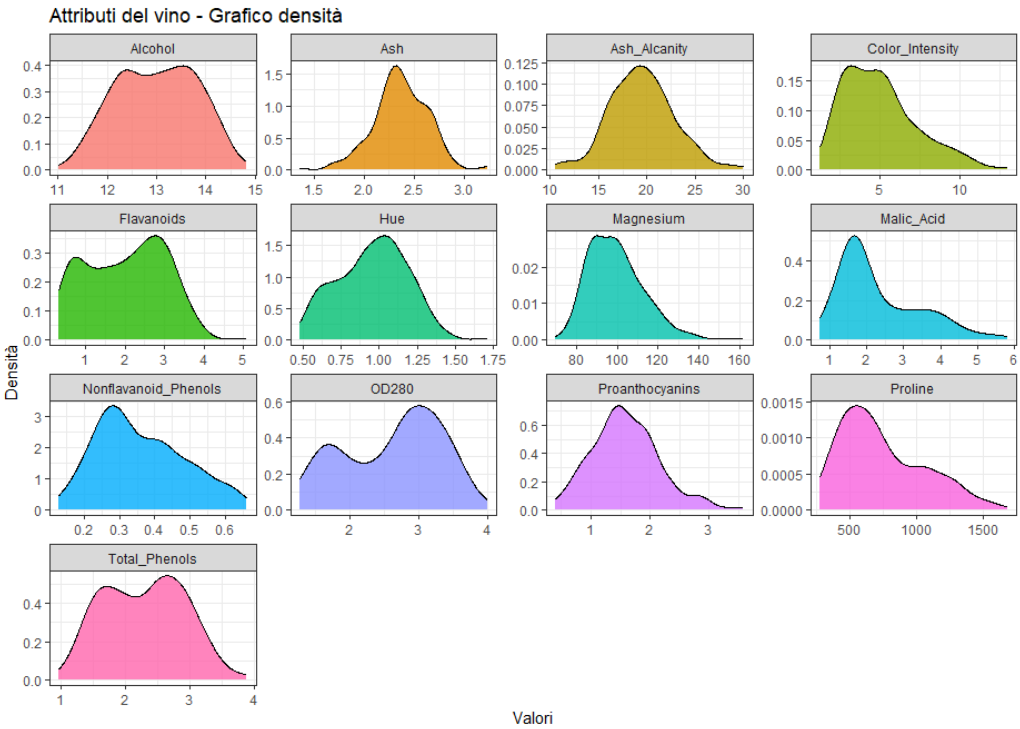

Figure 2: Distribuzione delle caratteristiche chimiche del vino tramite grafici di densità.

L'utilizzo di entrambe le tipologie di grafici, istogrammi e grafici di densità, consente una visione più completa: gli istogrammi forniscono un'interpretazione dei dati evidenziandone concentrazioni o valori atipici, mentre i grafici di densità permettono di osservare con maggiore chiarezza la presenza di picchi, la forma della

distribuzione e la variabilità complessiva.

Dagli istogrammi emergono ulteriori ipotesi relative agli outlier: osservando le barre di frequenza che si discostano dal resto della distribuzione, possiamo ipotizzarne la presenza.

In generale, non tutte le variabili seguono un andamento simmetrico: alcune mostrano marcate asimmetrie o code lunghe, mentre altre appaiono più regolari. Ad esempio, *Malic_Acid* e *Proline* presentano una **skewness** positiva, ossia un'*asimmetria a destra*, con dati maggiormente concentrati a sinistra e una lunga coda verso destra.

Inoltre, la variabile *Magnesium* mostra un andamento di tipo **leptocurtico**, caratterizzato da un picco alto e code pesanti. Questo significa che i dati sono fortemente concentrati attorno alla media e che c'è una maggiore frequenza di valori estremi.

La maggior parte delle altre variabili assume forme **mesocurtiche**, tipiche della normale. In questo caso, la distribuzione risulta intermedia tra leptocurtosi e platicurtosi, con una frequenza di valori estremi simile a quella attesa in una gaussiana standard.

Non ho invece riscontrato andamenti **platicurtici**, cioè caratterizzati da un picco piatto e code leggere. Tale configurazione indica dati meno concentrati attorno alla media e una ridotta presenza di valori estremi: in altre parole, una maggiore uniformità.

Dall'analisi degli istogrammi e dei grafici di densità emergono poi casi **bimodali**, come per *Alcohol*, *Color_Intensity*, *Flavanoids*, ecc. La presenza di due picchi suggerisce l'esistenza di sottogruppi, che verranno approfonditi nella sezione dedicata al Clustering.

Altre variabili, invece, mostrano un profilo **unimodale**, con un unico picco; ad esempio *Ash* e *Ash_Alcanity*.

Per avere conferma delle ipotesi fatte su **skewness** e **kurtosis** ho costruito una tabella con entrambi i valori per ognuna delle variabili:

Variabile	**Skewness**	**Kurtosis**
Alcohol	-0.0506	-0.8862
Malic_Acid	1.0222	0.2209
Ash	-0.1737	1.0329
Ash_Alcanity	0.2095	0.4023
Magnesium	1.0798	1.9566
Total_Phenols	0.0852	-0.8700
Flavanoids	0.0249	-0.9130
Nonflavanoid_Phenols	0.4426	-0.6792
Proanthocyanins	0.5085	0.4664
Color_Intensity	0.8540	0.3000
Hue	0.0207	-0.3975
OD280	-0.3021	-1.1111
Proline	0.7549	-0.3055

Table 3: Valori di skewness e kurtosis delle variabili del dataset ottenuti tramite indice di Fisher.

Per la skewness, valori prossimi a zero indicano una distribuzione simmetrica; valori positivi evidenziano una coda più lunga a destra (asimmetria positiva), mentre valori negativi indicano una coda più lunga a sinistra (asimmetria negativa).

Per la kurtosi, il valore di riferimento della normale è 3. In questo caso, però, è stata utilizzata la *excess kurtosis*, sottraendo 3, in modo che un valore pari a zero indichi una forma mesocurtica, valori positivi descrivano curve con picco alto e code pesanti (leptocurtiche), mentre valori negativi corrispondano a profili più piatti con code leggere (platicurtiche).

Pertanto, le considerazioni avanzate analizzando i grafici di densità risultano confermate: ad esempio, *Malic_Acid* e *Proline* presentano una skewness positiva relativamente alta, mentre *Magnesium*, con un valore di kurtosi intorno a 2, evidenzia un andamento leptocurtico. Ragionamenti analoghi si applicano al resto delle variabili. Infine, le variabili *OD280* e *Flavanoids* suggeriscono una forma platicurtica, seppur moderata, in contrasto con le ipotesi visive derivanti dai grafici.

Ho proseguito l'analisi esplorativa delle variabili chimiche generando i *boxplot* per ciascuna feature (Figura 3). Come per gli istogrammi e i grafici di densità, ho utilizzato il dataset in *long format* ("*long_wines*"), così da facilitare la creazione dei grafici con `ggplot`.

Ogni boxplot rappresenta la distribuzione dei valori di una variabile:

- il rettangolo centrale indica la **distanza interquartile** (IQR), ossia l'intervallo tra il primo e il terzo quartile, che racchiude il 50% dei dati centrali;
- la linea interna rappresenta la mediana;

- i baffi si estendono fino ai valori minimi e massimi, escludendo i valori anomali;
- i punti al di fuori dei baffi identificano gli *outlier*.

Questa analisi permette di confermare e arricchire quanto già ipotizzato sugli outlier: oltre alle variabili già individuate, emergono anche *Hue* e *Ash*. Inoltre, i boxplot offrono un'ulteriore conferma riguardo alla simmetria e alla curtosi delle distribuzioni: attraverso la forma della scatola è infatti possibile valutare come i dati siano distribuiti rispetto alla mediana e quanto risultino concentrati attorno ad essa oppure dispersi nelle code.

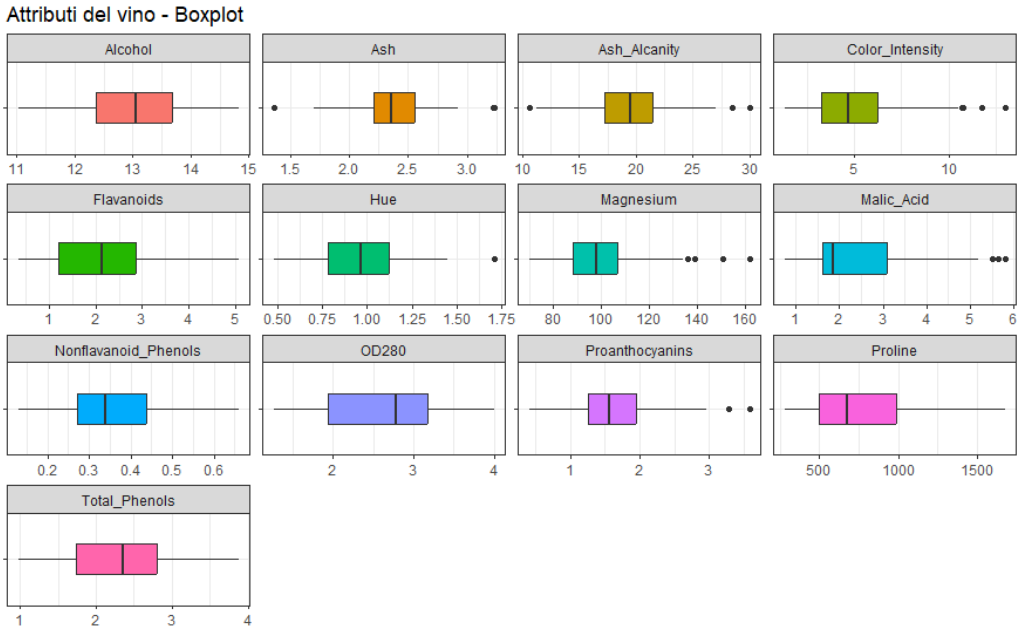

Figure 3: Grafici boxplot delle caratteristiche chimiche del vino

Per indagare le relazioni tra le variabili e individuare possibili ridondanze informative, ho calcolato la matrice di correlazione sulle features del dataset e l'ho visualizzata tramite la funzione `corrplot`.

Il **coefficiente di correlazione di Pearson** misura l'intensità e la direzione della relazione lineare tra due variabili x e y, ed è definito come:

$$-1 \leq \rho_{xy} = \frac{\mathrm{cov}(x, y)}{\sigma_x \, \sigma_y} \leq 1$$

dove σ_x e σ_y rappresentano le deviazioni standard di x e y, mentre $\mathrm{cov}(x, y)$ è la loro covarianza. Valori prossimi a $+1$ indicano una forte correlazione positiva, valori prossimi a -1 una forte correlazione negativa, mentre valori vicini a 0 indicano assenza di relazione lineare. Nella figura, la scala di colori va dal bianco al rosso: le tonalità più intense indicano una forte correlazione (positiva o negativa), mentre tonalità intermedie indicano correlazioni deboli.

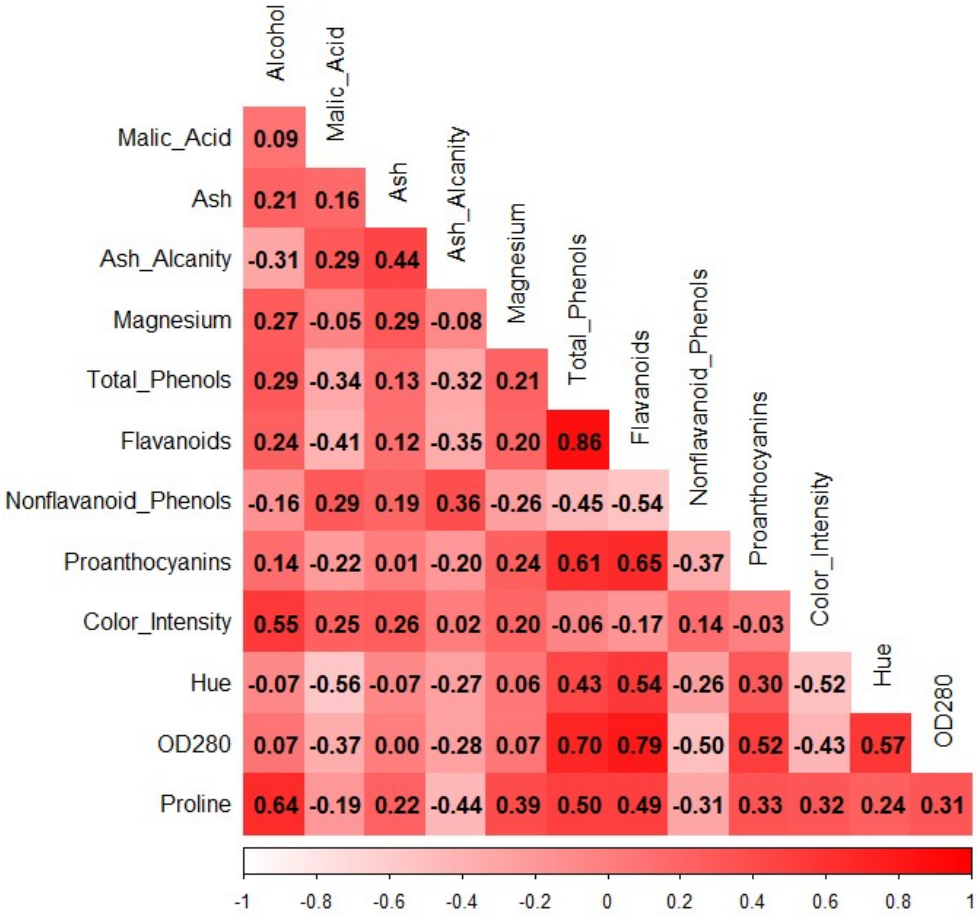

Figure 4: Matrice di correlazione tra le feature

Dalla Figura 4 emerge chiaramente che alcune variabili chimiche presentano forti correlazioni tra loro. In particolare, si osservano legami significativi tra *Total_Phenols* e *Flavanoids* ($\rho = 0.86$), così come tra *OD280* e *Flavanoids* ($\rho = 0.79$), evidenziando una possibile ridondanza informativa.

Per analizzare più da vicino la dipendenza tra *Total_Phenols* e *Flavanoids* da un lato, e tra *OD280* e *Flavanoids* dall'altro, ho creato dei grafici a dispersione (**scatterplot**), con sovrapposte le **rette di regressione lineare**, che rappresentano la migliore approssimazione secondo il criterio dei minimi quadrati.

Nel primo grafico (Figura 5(a)) emerge una correlazione lineare positiva: all'aumentare dei *Total_Phenols*, aumentano anche i *Flavanoids*, confermando quanto suggerito dalla matrice di correlazione. Nel secondo grafico (Figura 5(b)), la relazione resta lineare, ma i punti si distribuiscono in modo meno compatto attorno alla retta di regressione. Questo andamento, in linea con i valori della matrice di correlazione, suggerisce una dipendenza positiva più debole e una maggiore variabilità dei dati.

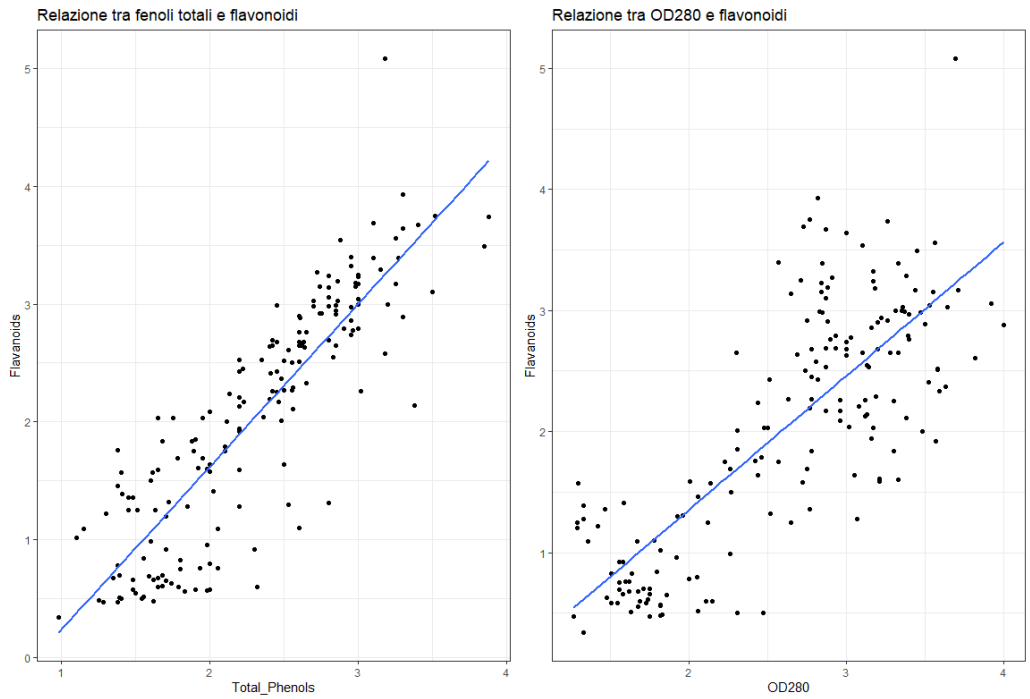

Figure 5: Scatterplot di *Total_Phenols* e *Flavanoids* (a) e *OD280* e *Flavanoids* (b) con retta di regressione lineare

3 PCA - Analisi delle Componenti Principali

Ho proceduto con l'**analisi delle componenti principali** (PCA), una tecnica utilizzata per ridurre la dimensionalità di un dataset, preservando al massimo la varianza contenuta nei dati originali.

In questo caso, avendo a disposizione variabili chimiche con scale di misura differenti, ho applicato la PCA standardizzando i dati, cioè lavorando sulla **matrice di correlazione**: ogni variabile viene trasformata in modo da avere media pari a 0 e varianza pari a 1. Per farlo ho utilizzato la funzione `prcomp`, predefinita in *Rstudio*, impostando `center = TRUE` e `scale = TRUE`.

Ho, poi, stampato a schermo un riepilogo della PCA:

- **Deviazione standard**: indica la dispersione delle componenti principali, ossia quanto ciascuna componente principale si discosta dalla media;
- **Proporzione della varianza spiegata**: quantifica la variabilità totale spiegata da ogni componente principale;
- **Varianza cumulativa**: rappresenta la somma progressiva delle proporzioni di varianza e indica quanta variabilità totale è spiegata considerando via via un numero crescente di componenti principali.

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9	PC10	PC11	PC12	PC13
Standard deviation	2.169	1.5802	1.2025	0.9586	0.9237	0.8010	0.7423	0.5903	0.5375	0.5009	0.4752	0.4108	0.3215
Proportion of Variance	0.362	0.1921	0.1112	0.0707	0.0656	0.0494	0.0424	0.0268	0.0222	0.0193	0.0174	0.0130	0.0080
Cumulative Proportion	0.362	0.5541	0.6653	0.7360	0.8016	0.8510	0.8934	0.9202	0.9424	0.9617	0.9791	0.9921	1.0000

Table 4: Risultati PCA: deviazioni standard, proporzioni di varianza spiegata e proporzioni cumulative.

Proseguendo, ho calcolato gli autovalori della matrice di correlazione, che misurano la quantità di varianza spiegata lungo ciascuna componente principale. In particolare:

$$\text{Varianza spiegata da } PC_i = \frac{\lambda_i}{\sum_{j=1}^{n} \lambda_j}$$

con λ_i autovalore associato a PC_i.

Per farlo, ho elevato al quadrato la deviazione standard, nonché la radice quadrata della varianza:

$$\text{Varianza} = \text{Deviazione standard}^2 = \sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

dove $\bar{x}$ rappresenta la media e x_i l'i-esimo valore osservato.

Ho inserito in un data frame, denominato "*wines_scree*", ciascuna delle componenti principali con la relativa varianza spiegata (ossia l'autovalore associato).

Successivamente, tramite la funzione `get_pca_var` della libreria *factoextra*, ho estratto il **cos2** (cos^2) delle variabili, che misura quanto bene una componente principale "riassume" o "spiega" una singola feature. Corrisponde al coseno quadrato dell'angolo tra il vettore che rappresenta il campione e il suo vettore proiettato sulla componente principale, misurato a partire dall'origine.

Per un primo criterio di scelta del numero di componenti principali, ho generato un grafico di correlazione tra componenti principali e variabili del dataset, utilizzando i valori di *cos2* ottenuti nel passaggio precedente. Questo grafico permette di valutare quanto ciascuna variabile contribuisca a spiegare una specifica componente principale. Variabili con valori di *cos2* più alti rappresentano maggiormente la componente corrispondente, mentre valori bassi indicano una scarsa rappresentatività. In particolare, la prima componente principale sintetizza le informazioni di *Flavanoids* e *Total_Phenols*, la seconda la *Color_Intensity* e la terza *Ash* e *Ash_Alcanity*.

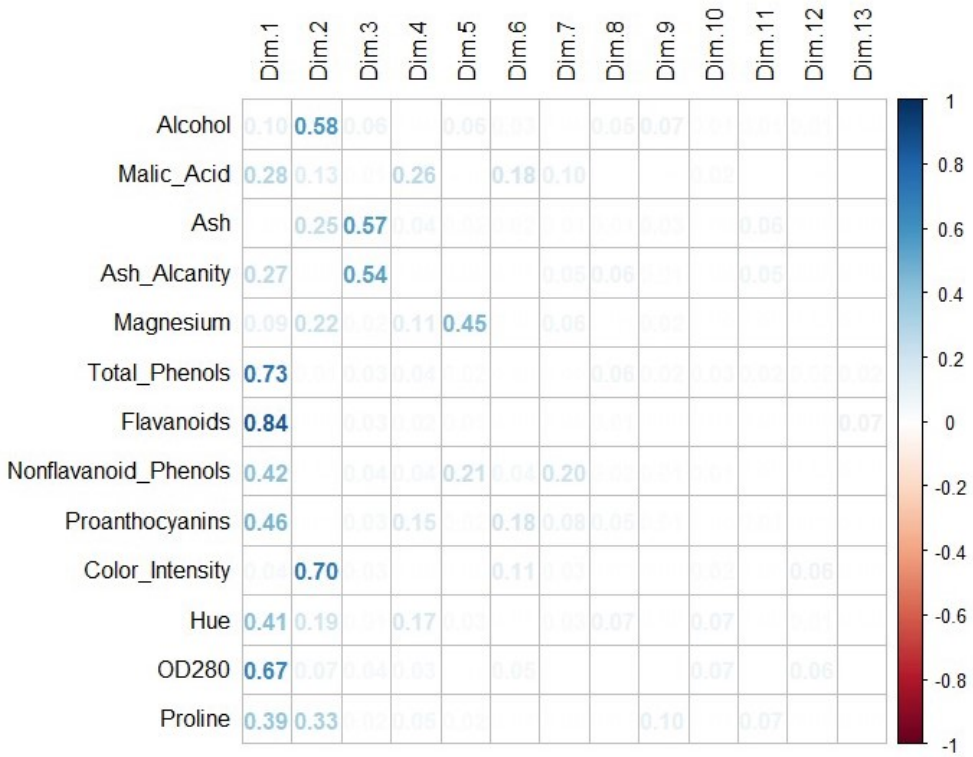

Figure 6: Grafico di correlazione tra variabili e componenti principali

Analizzando il grafico (Figura 6), si nota che le prime tre componenti principali sono ben rappresentate, con valori di *cos2* piuttosto elevati. Ciò indica che queste componenti catturano in modo affidabile la struttura del dataset.

La quarta componente, invece, mostra valori bassi per tutte le variabili, suggerendo che nessuna di esse contribuisce in modo significativo. In questo senso, la quarta componente potrebbe essere considerata rumore, con un ruolo marginale nell'interpretazione dei dati.

Infine, la quinta è più rappresentativa della precedente, seppur con valori moderati. Questo può suggerire che le prime cinque componenti catturano gran parte della variabilità totale.

Per conferma, ho costruito lo **scree plot** delle componenti principali e il grafico della varianza cumulativa. Nel primo grafico ogni punto rappresenta l'autovalore di una componente, che misura la varianza spiegata lungo quell'asse. La linea orizzontale rossa rappresenta il **criterio di Kaiser**, utile per individuare le componenti da mantenere: vengono considerate rilevanti solo quelle con autovalore superiore alla media. Poiché la PCA è stata applicata sulla matrice di correlazione (dove la varianza è normalizzata a 1), questo equivale a selezionare le componenti con autovalore maggiore di 1.

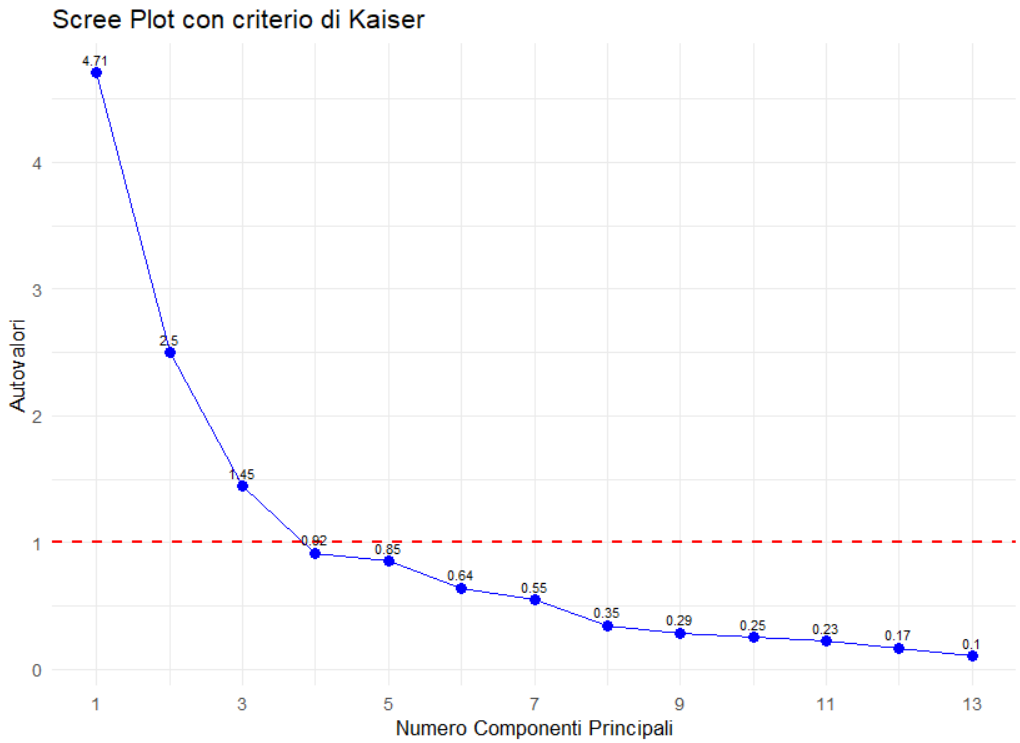

Figure 7: Scree plot per la scelta del numero ottimale di componenti principali

Per il secondo grafico ho dapprima calcolato la varianza cumulativa secondo la formula:

$$\frac{\sum_{i=1}^{k} \lambda_i}{\sum_{j=1}^{13} \lambda_j} \times 100$$

con $k \leq 13$ e $13 = \#variabili$.

Dopodiché, ho creato un data frame contenente il numero di componenti principali e la corrispondente varianza cumulativa. Infine, ho utilizzato questi dati per costruire il grafico, che permette di visualizzare quanta parte della variabilità totale (in percentuale) è spiegata dalle componenti principali.

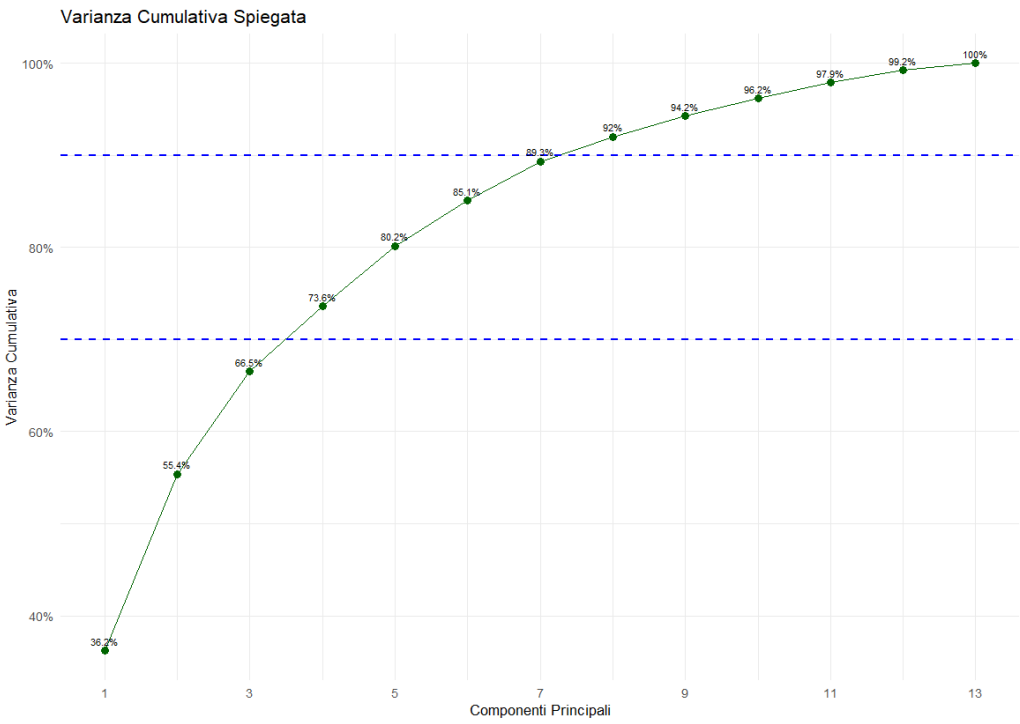

Figure 8: Grafico della varianza cumulativa spiegata dalle componenti principali

Lo scree plot (Figura 7) suggerisce di scegliere $k = 3$ componenti principali. Tuttavia, osservando il grafico della varianza cumulativa, si nota che le prime tre componenti spiegano complessivamente circa il 65.5% della varianza totale. Generalmente, la scelta del numero di componenti principali ricade su un intervallo di varianza spiegata compreso tra il 70% e il 90%. In questo caso, però, ho trovato un compromesso tra quantità di informazione mantenuta e possibilità di visualizzazione grafica dei dati nello spazio ridotto, proseguendo con $k = 3$ (vedi Figura 12).

4 Clustering

Ho concluso l'esplorazione del dataset applicando il clustering dei dati.

Il clustering è un insieme di tecniche non supervisionate di analisi multivariata, finalizzate all'identificazione e al raggruppamento di elementi simili all'interno di un dataset. Formalmente, consiste nell'individuare una partizione dell'insieme degli indici $\{1, \ldots, n\}$ in k sottoinsiemi disgiunti $\{I_1, \ldots, I_k\}$, tali che:

- $I_l \cap I_s = \emptyset$ per ogni $l \neq s$
- $\bigcup_{l=1}^{k} I_l = \{1, \ldots, n\}$

I cluster sono definiti come: $C_l = \{X_i \mid i \in I_l\}$, con $l = 1, \ldots, k$ e le etichette dei gruppi vengono assegnate a posteriori, dopo la costruzione dei cluster.

Ho applicato due principali tipologie di clustering:

- **Partitivo**: suddivide un insieme di dati in un numero predefinito di gruppi (k cluster), assegnando ogni osservazione ad un unico cluster in modo da massimizzare l'omogeneità interna e la separazione tra i gruppi;
- **Gerarchico agglomerativo** (*bottom-up*): si assume che inizialmente ogni punto corrisponda ad un cluster; ad ogni passo, poi, vengono fusi i cluster più "vicini" fino ad ottenere un singolo grande cluster. Questi algoritmi necessitano di misure per valutare la similarità tra clusters per scegliere la coppia di cluster da fondere ad ogni passso.

4.1 K-means

Dopo aver analizzato le componenti principali del dataset *wines*, ho applicato l'algoritmo **k-means**. Questo è un algoritmo di *apprendimento non supervisionato* che appartiene alla famiglia dei **clustering partitivi** e utilizzato per suddividere i campioni in gruppi (**cluster**). Per *non supervisionato* si intende che il dataset non contiene etichette note: l'algoritmo non deve stimare un output noto, ma individuare strutture nascoste nei dati, motivo per cui è stata tolta la colonna *Customer_Segment*.

L'obiettivo principale dell'algoritmo *k-means* è quello di minimizzare la somma delle distanze quadratiche all'interno dei cluster, ossia:

$$\min_{\pi} \sum_{l=1}^{k} \sum_{i \in I_l} \|X_i - c_l\|^2$$

dove:

- $\pi = \{I_1, \ldots, I_k\}$ è la partizione dell'insieme degli indici,
- $c_l = \frac{1}{|I_l|} \sum_{i \in I_l} X_i$ è il centroide del cluster l.

Per poter applicare l'algoritmo, ho innanzitutto standardizzato le variabili del dataset tramite la funzione `scale`. La standardizzazione, in questo caso, è necessaria poiché le variabili originali presentano scale e unità di misura differenti (ad esempio, l'alcol è misurato in percentuale, mentre il magnesio in mg/L): senza questa operazione, le variabili con valori numerici più grandi avrebbero avuto un peso sproporzionato nel calcolo delle distanze euclidee.

Prima di procedere con il clustering ho fissato dei *seeds* casuali tramite il comando `set.seed(1234)`. L'inizializzazione dei centroidi nel k-means avviene infatti in maniera casuale e può condurre a soluzioni differenti a seconda delle scelte iniziali. Pertanto ho impostato dei *seeds*, così da rendere i risultati **riproducibili**: ad ogni esecuzione del codice, i centroidi iniziali vengono scelti nello stesso modo, garantendo che la partizione

finale dei dati sia sempre identica.

Per determinare il numero appropriato di cluster, ho applicato la **tecnica del gomito (elbow method)**: ho eseguito più volte il k-means sul dataset normalizzato *wines_norm* variando il numero di cluster da 1 a 10. Per ciascun valore di k ho calcolato:

- la **somma dei quadrati tra i cluster** (*betweenss*), che misura quanto i cluster sono distanti tra loro, quindi quanto la partizione separa bene i dati. Un BSS elevato indica che i cluster sono ben distinti e che la partizione separa efficacemente i dati. Al contrario, un BSS basso suggerisce che i cluster si sovrappongono e non sono chiaramente definiti;
- la **somma dei quadrati all'interno dei cluster** (*tot.withinss*), che misura quanto i punti all'interno di un cluster sono vicini tra loro. Un WSS elevato indica che i punti dati sono sparsi e meno simili tra loro, suggerendo che il metodo di clustering scelto potrebbe non essere appropriato. Al contrario, un WSS basso significa che i punti dati sono strettamente correlati, indicando un risultato positivo del clustering.

Successivamente, ho rappresentato graficamente entrambe le metriche. La scelta del numero ottimale di cluster k corrisponde al punto in cui la curva genera un "gomito" nel grafico.

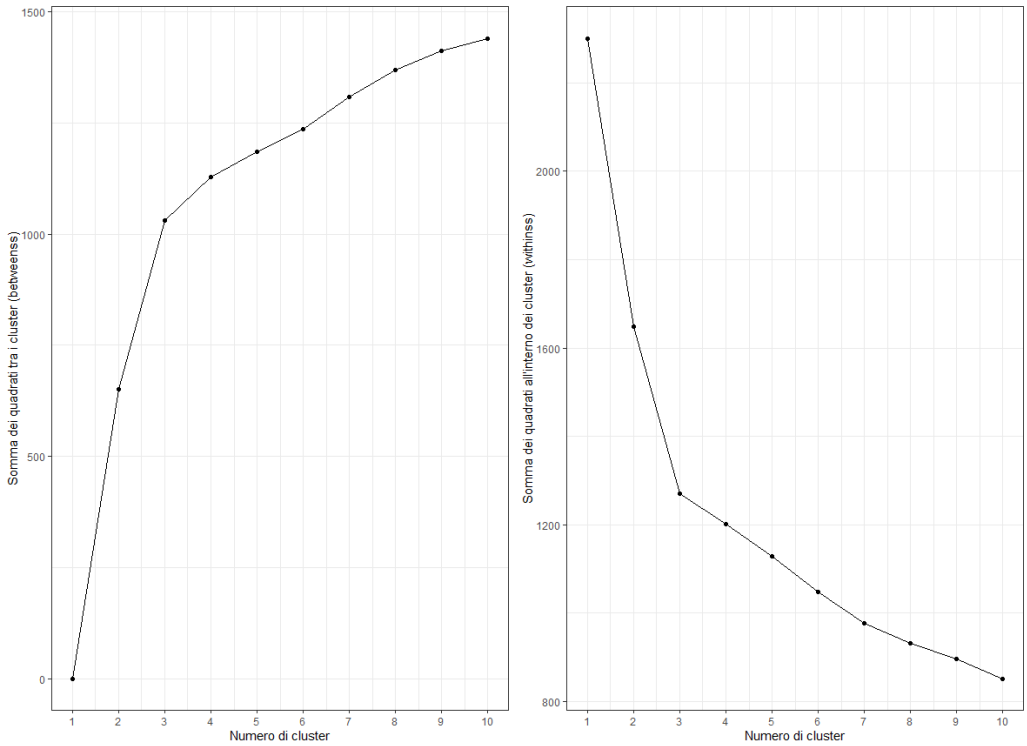

Figure 9: Tecnica del gomito per grafici di somma dei quadrati intercluster (a) e intracluster (b)

Dalla Figura 9 si evince che il numero ottimale k di cluster è 3. Pertanto ho eseguito il k-means con $k = 3$.
Successivamente ho calcolato le medie di ciascuna variabile chimica all'interno di ogni cluster tramite `aggregate`, ottenendo una panoramica delle caratteristiche tipiche dei tre gruppi ottenuti.

Group	Alcohol	Mal._Ac.	Ash	Ash_Alc.	Magn.	Tot._Ph.	Flav.	Nonfl._Ph.	Proa.	Color_Int.	Hue	OD280	Proline
1	13.67677	1.997903	2.466290	17.46290	107.96774	2.847581	3.003226	0.292097	1.922097	5.453548	1.065484	3.163387	1100.226
2	12.25092	1.897385	2.231231	20.06308	92.73846	2.247692	2.050000	0.357692	1.624154	2.973077	1.062708	2.803385	510.169
3	13.13412	3.307255	2.417647	21.24118	98.66667	1.683922	0.818824	0.451961	1.145882	7.234706	0.691961	1.696667	619.059

Table 5: Medie delle variabili chimiche per ciascun cluster di vini

Dall'analisi della Tabella 5 emergono tre profili di vino distinti:

- Il primo gruppo è caratterizzato da un contenuto alcolico medio più elevato e da un livello di prolina molto alto, accompagnati da valori elevati di fenoli totali e flavonoidi. Questi parametri indicano vini più corposi, complessi e strutturati, con un potenziale antiossidante maggiore e una buona propensione all'invecchiamento.

- Il secondo gruppo, al contrario, presenta un contenuto alcolico più basso e valori ridotti di prolina, fenoli totali e flavonoidi. Inoltre, il colore risulta meno intenso rispetto agli altri cluster. Queste caratteristiche suggeriscono vini più leggeri e freschi, con un profilo meno complesso e probabilmente più immediato al consumo.

- Il terzo gruppo si distingue invece per l'elevato contenuto di acido malico, che conferisce una marcata acidità, e per l'intensità di colore decisamente più alta rispetto agli altri cluster. I valori più bassi di flavonoidi e fenoli totali indicano una struttura meno acida, mentre la tonalità del colore (*Hue*) più bassa suggerisce vini con una maggiore componente rossa. Questi aspetti fanno pensare a vini più giovani, con caratteristiche aromatiche particolari.

Per visualizzare le differenze tra i cluster e le relazioni tra le variabili, ho realizzato un **pair plot**, tramite la funzione `ggpairs` della libreria *GGally*. Si tratta di una matrice di scatterplot (in questo caso triangolare inferiore) in cui ogni variabile numerica è confrontata con tutte le altre. Questo consente di osservare visivamente eventuali correlazioni e schemi di separazione tra gruppi. Sulla diagonale sono invece visualizzate le distribuzioni delle singole variabili per ognuno dei cluster.

Analizzando la Figura 10, si nota che alcune coppie di variabili mostrano cluster ben distinti, suggerendo che queste caratteristiche chimiche contribuiscono in modo significativo alla separazione dei vini. Ad esempio, la *Proline* sembrerebbe una variabile molto informativa nella separazione dei gruppi; infatti, per la maggior parte degli scatterplot di cui fa parte, i cluster risultano ben distinti. Al contrario *Ash* e *Ash_Alcanity* sembrerebbero le variabili meno informative per la separazione, poiché i cluster risultano tutti sovrapposti.

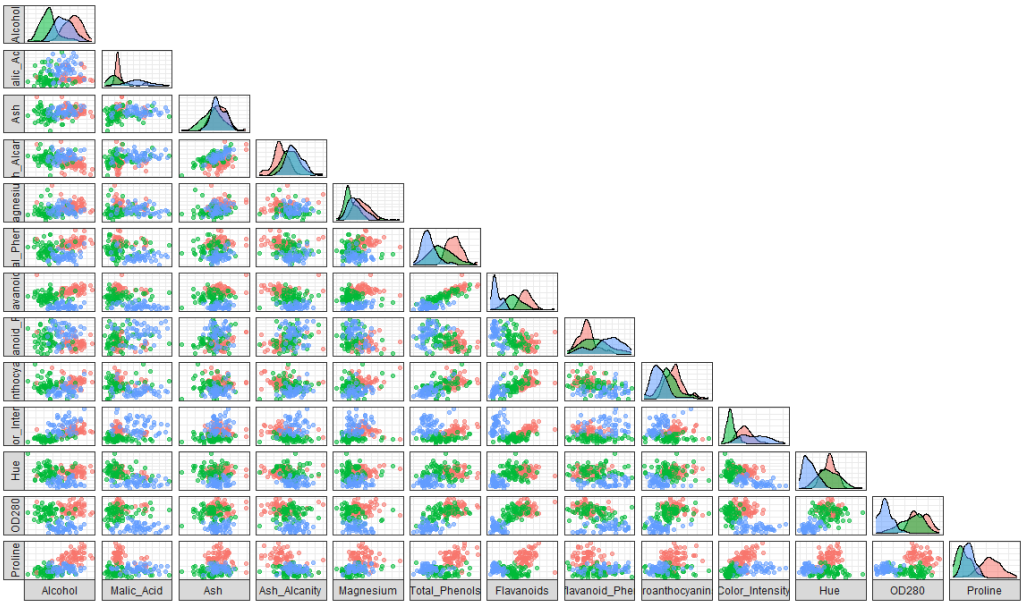

Figure 10: Pair plot delle variabili chimiche dei vini

In conclusione dell'analisi con k-means, ho effettuato un'ulteriore verifica sul numero di cluster scelto, valutando la qualità del clustering tramite l'**indice Silhouette**. Per ciascun punto del dataset, l'indice di silhouette misura quanto bene il punto è assegnato al proprio cluster rispetto a quanto sarebbe stato vicino agli altri cluster: se il valore è alto (≈ 1), significa che il punto è ben inserito nel suo cluster e distante dagli altri; se il valore è basso o negativo, significa che il punto è vicino ad altri cluster o addirittura assegnato al cluster sbagliato.

Attraverso la funzione `fviz_nbclust` ho ottenuto il grafico rappresentante il valore medio dell'indice Silhouette per ogni k numero di cluster. L'andamento del grafico conferma che $k = 3$ rappresenta la scelta più appropriata, in quanto corrisponde al massimo valore dell'indice.

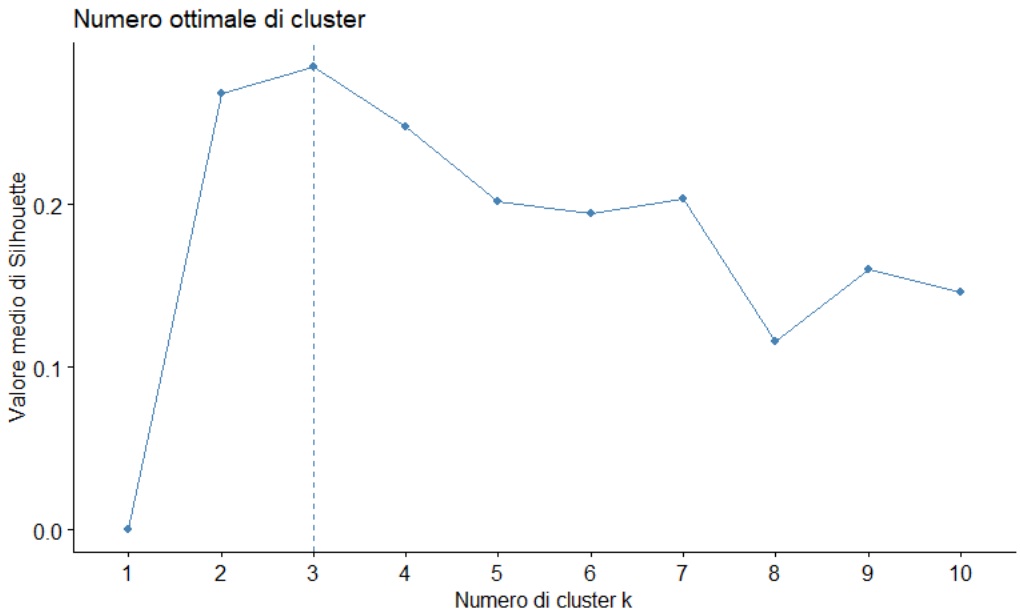

Figure 11: Grafico dell'indice Silhouette medio per diversi valori di k

Tornando alla PCA e alla visualizzazione dei dati, per interpretarli al meglio i dati, ho proiettato i campioni nello spazio tridimensionale generato dalle prime tre componenti principali e li ho suddivisi in base ai cluster ottenuti con il k-means.

A ciascun cluster ho assegnato un colore distintivo: rispettivamente rosso, verde e blu. Successivamente, ho costruito uno scatterplot 3D interattivo, che permette di osservare la disposizione dei campioni nello spazio delle prime tre componenti principali e di identificare visivamente la separazione tra i cluster.

La possibilità di ruotare e ingrandire il grafico facilita inoltre l'esplorazione della struttura dei cluster e delle relazioni tra le componenti principali, consentendo di evidenziare eventuali pattern, concentrazioni o sovrapposizioni tra gruppi.

Per agevolare la condivisione e l'interpretazione dei risultati in questo lavoro, ho inoltre generato scatterplot bidimensionali per ciascuna coppia di componenti principali: PC1 vs PC2, PC1 vs PC3 e PC2 vs PC3.

Nella prospettiva PC1 vs PC2 i cluster risultano chiaramente separati, evidenziando una suddivisione netta dei gruppi. Nella prospettiva PC1 vs PC3 la separazione è meno marcata, ma i cluster restano comunque distinguibili. Infine, nella prospettiva PC2 vs PC3 i cluster appaiono meno definiti: in particolare, il primo e il terzo cluster mostrano una parziale sovrapposizione, mentre il secondo cluster rimane separato e ben distinto dagli altri.

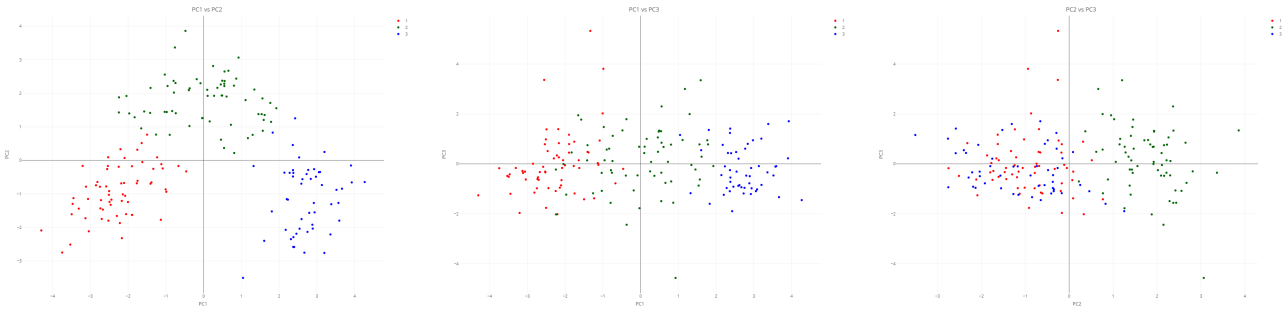

(a) PC1 vs PC2 (b) PC1 vs PC3 (c) PC2 vs PC3

Figure 12: Scatterplot delle coppie di componenti principali con i cluster colorati.

4.2 Dendrogramma

L'analisi dei cluster termina con un esempio di clustering gerarchico di tipo agglomerativo, rappresentato attraverso un **dendrogramma**. Un dendrogramma è un diagramma ad albero che rappresenta visivamente la disposizione dei cluster prodotti dal clustering gerarchico. Esso è costituito da diversi componenti chiave: rami, foglie e nodi. Le foglie rappresentano singoli punti dati o osservazioni, mentre i rami indicano le relazioni tra questi punti. I nodi sono i punti in cui i rami si dividono, a significare la fusione di cluster.

L'asse verticale rappresenta la distanza tra i cluster al momento della fusione: più il livello a cui due gruppi si uniscono è elevato, maggiore è la loro differenza in termini di caratteristiche chimiche.

Ho utilizzato gli **scores** ottenuti grazie alla PCA, ossia le coordinate dei campioni rispetto alle nuove componenti principali (in questo caso le prime 3). A partire da questi scores, ho costruito la matrice delle distanze euclidee per misurare la similarità tra i campioni.

Successivamente, ho applicato il clustering gerarchico agglomerativo con il **Ward linkage method** con distanze euclidee al quadrato (`ward.D2`), che minimizza la varianza totale all'interno del cluster. Ho scelto questo metodo perché tende a produrre cluster più simili tra loro, oltre ad essere compatti ed uniformi. La libertà di scelta nella distanza e nel linkage method è dovuta alla flessibilità del dendrogramma.

Infine, ho rappresentato i risultati tramite un dendrogramma, utilizzando la funzione `fviz_dend`, e ho suddiviso i dati in 3 cluster ($k = 3$), in accordo con quanto suggerito sia dall'Elbow Method (Figura 9) sia dall'indice Silhouette (Figura 11). Nel grafico (Figura 13) i tre cluster sono evidenziati con colori differenti (verde, arancione e viola) e risultano piuttosto simili sia in termini di variabilità intracluster sia di densità e compattezza, in accordo con il Ward linkage method.

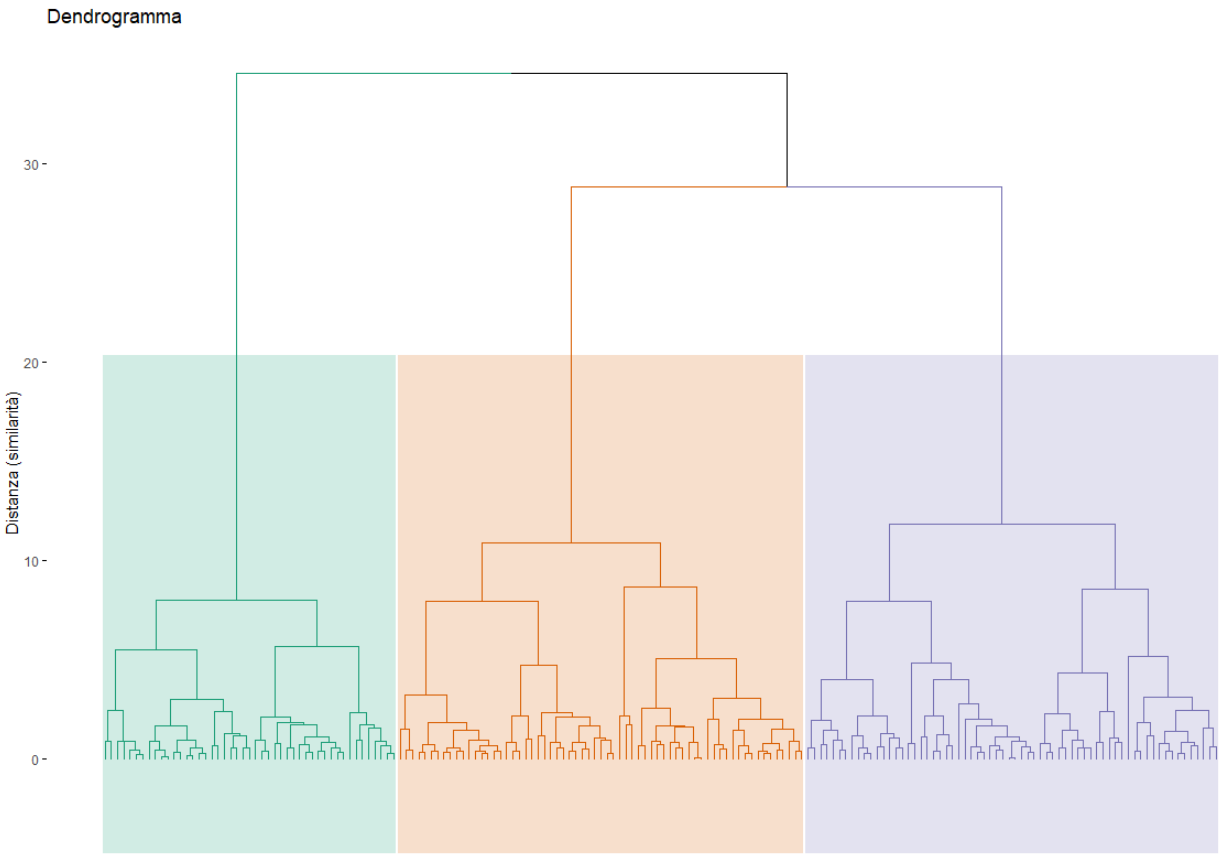

Figure 13: Dendrogramma costruito utilizzando il Ward linkage method e la distanza euclidea.